

사용자 요구 변화를 추적하는 다중 턴 쇼핑 에이전트

김진욱¹, 노태형², 여해인², 한경식^{1,2}

¹Department of Data Science, Hanyang University, Seoul, Republic of Korea

²Department of Artificial Intelligence, Hanyang University, Seoul, Republic of Korea

Motivation

Limitations & Research Gap


- 추천 시스템은 사용자 프로필과 과거 상호작용을 기반으로 선호와 의도를 추론하고, 이를 후보 검색과 순위화에 활용해 추천 정확도를 높여 왔다.
- 고정된 데이터에서 다음 아이템을 예측하는 방식은 실제 쇼핑 과정에서 변화하는 요구, 상품 거절 이유, 재고·가격·배송과 같은 현재 정보, 그리고 여러 턴의 대화 맥락을 충분히 반영하기 어렵다.

The Need for Dynamic State Grounding

- 쇼핑 에이전트는 대화 과정에서 지속적으로 변화하는 사용자의 선호와 구매 상황에서의 여러 제약 조건을 이해할 수 있어야 한다.
- 동적 상태 그라운드링(Dynamic State Grounding)은 대화에서 조건과 추천·거절·수락 이력을 지속적으로 축적하고, 이를 질의 생성 및 재순위화 과정에 반영하여 사용자의 의도를 정교하게 추적한다.

본 연구에서는 대화 과정에서 **실시간 상품·리뷰 정보**를 바탕으로 상태를 **지속적으로 업데이트**하고, 이에 따라 **추천 순위를 재조정**하는 상태 기반 쇼핑 에이전트를 제안한다.

Methodology



Main Experiment

- 에이전트는 **이전 대화 상태를 유지할 때** 현재 턴의 정보만 사용할 때보다 **사용자 요구를 더 정확하게 보존함**. (Final State F1 +0.258)
- 이전 상태를 현재 턴의 새로운 **정보로 중복 인식**하면서 **턴별 상태 변화 추적 성능은 감소함**. (State Diff F1 -0.138)

Metric	Full	No-memory	Difference	95% bootstrap CI
Final State micro-F1	0.758	0.500	+0.258	[+0.172, +0.334]
State Diff micro-F1	0.562	0.700	-0.138	[-0.222, -0.056]
Policy accuracy	0.802	0.741	+0.062	[-0.111, +0.222]
Recommendation reach	0.808	0.744	+0.064	[-0.103, +0.231]
Hard-filter completion	0.630	0.444	+0.185	[+0.000, +0.363]

태블릿 구매를 가정한 20개의 독립적인 다중 턴 시나리오(총 81턴)에서, 이전 Dialogue State를 다음 턴까지 유지하는 조건과 현재 턴의 정보만 사용하는 조건을 비교

Diagnostic Analysis

- figure(a): 추론된 Dialogue State를 **정답 상태(Gold-State)**로 대체하자 Policy, Recommendation Reach, Hard-filter 성능이 모두 **1.0으로 회복함**.
- figure(b): 동일한 두 조건에서 리뷰 기반 점수를 제거한 경우, **Top-1 추천의 55.6%, Top-3 상품 순서의 87.3%가 변화함**.

Metric	Actual Full	Gold-State	Recovery
Policy	0.802	1.000	+0.198
Reach	0.808	1.000	+0.192
Hard-filter	0.630	1.000	+0.370

Ranking behavior	Result
Top-1 changed	55.6%
Top-3 order changed	87.3%
Mean top-3 Jaccard	0.522

▲ figure (a) - Gold-State 대체를 통한 오류 원인 진단 ▲ figure (b) - 리뷰 정보의 상품 순위 기여도 분석

Conclusion & Future Work

- Amazon Reviews 2023에서 추출한 태블릿 117개·리뷰 7,552개를 바탕으로 구성된 20개의 다중 턴 구매 시나리오를 활용한 쇼핑 에이전트 환경에서, Dialogue State의 지속적 관리가 누적된 사용자 요구를 보존하는 데 효과적임을 확인함. 또한 리뷰 정보가 실제 상품 순위 결정에 영향을 미쳤으며, Gold-State 분석을 통해 주요 성능 손실이 상태 추론·구성 과정에서 발생함을 확인.
- 과거 상태와 현재 턴의 변화를 보다 정확히 구분할 수 있도록 상태 추론·갱신 방식을 개선하고, 리뷰에 의해 변화한 상품 순위가 실제 추천 정확도와 사용자 관점의 추천 품질 향상으로 이어지는지를 검증할 필요가 있음. 또한 가격·재고·배송 등 동적 정보와 다양한 상품군을 포함하는 보다 현실적인 쇼핑 환경으로 평가 범위를 확장하고자 함.