

정책 유형론 기반 LLM 에이전트 정책 시뮬레이션 평가 프레임워크

Minseo Jeong¹, Haein Yeo², Junghyun Kim¹, Beejin Son², Kyungsik Han^{1, 2}

¹ Department of Data Science, Hanyang University, Seoul, Republic of Korea

² Department of Artificial Intelligence, Hanyang University, Seoul, Republic of Korea

Motivation

Limitations & Research Gap

- LLM 기반 다중 에이전트 정책 시뮬레이션의 평가가 최종 결과의 예측 정확도에 집중되어 있고, 표준화된 평가 기준이 부재함
- 시뮬레이션이 정책의 유형과 분야에 따른 차이를 반영하는지 확인하기 어려우며, 이해관계자 간 상호작용과 정책 맥락을 검토할 수 있는 평가 방법이 필요함

Lowi의 정책 유형론

정책 유형	비용과 편익의 분포	집단 간 관계 양상
배분 (Distributive)	편익 집중, 비용 분산	집단 간 상호 수용
규제 (Regulatory)	편익과 비용의 대칭적 총돌	이익집단 간 대립
재분배 (Redistributive)	계층 간 편익·비용의 이전	계층 집단 간 갈등


본 연구는 AI 에이전트 정책 시뮬레이션을 평가하기 위해 **정확성과 다양성** 두 축의 지표를 미시·중위·거시 수준에서 구축하고, **Lowi의 정책 유형론**에 따른 해석 기준의 필요성을 제시한다.

Methodology


Simulation Evaluation Framework

- AI 에이전트 정책 시뮬레이션**: 정책 투입에서 영향에 이르는 5단계의 ToC 체인을 기반으로, 다섯 명의 정책 이해관계자 에이전트가 하나의 그룹을 이루어 정책 효과를 예측하는 토의를 수행함
- 시뮬레이션 평가 체계**: 정확성과 다양성 두 축[1]에 걸친 9개 지표를 개별 발화의 미시 수준, 이해관계자 상호작용의 중위 수준, 결과 분포의 거시 수준에서 각각 정의함

Theory of Change (ToC) Simulation Chain



Multi-Agent Discussion Scenario



축	수준	지표	정의	산출 방식
Accuracy 사실 근거와 정합성	미시	Grounding coverage	근거 출처 추적 가능성	근거 3종에 대한 최대 유사도 할당
	중위	Convergence	단계 내 추정치 일치도	CV 중앙값의 역방향 정규화
	중위	Value uptake	선행 수치의 채택 정도	선행 발화의 값을 인용한 발화 비율
	거시	Target error	실제 값 대비 예측 오차	APE와 bootstrap 95% 신뢰구간
	거시	Calibration	예측 분포의 부합도	예측구간 포함 여부와 PIT
Diversity 관점과 결과의 분포	미시	Role explained variance	역할이 설명하는 변동 비율	variance decomposition 기반 ICC
	미시	Semantic dispersion	발화 간 서술 내용 차이	발화 쌍 간 cosine distance 평균
	중위	Interaction structure diversity	토의 전개 구조의 다양성	그래프 유형 분포의 normalized entropy
	거시	Outcome space width	최종 결과의 분포 폭	최종 추정치의 CV, IQR


[1] H. Lee and J. Seering, "Accuracy, Diversity, and Reflection: Purpose-driven Evaluation for Social Simulation," presented at PoliSim@CHI 2026: LLM Agent Simulation for Policy, a workshop at CHI 2026, Barcelona, Spain, Apr. 16, 2026.

Main Experiment

- 배분 유형의 AI 인재 양성 정책** BK21(한국)과 100E(싱가포르), **규제 유형의 의료비 청구 제한 정책** NSA(미국) 시뮬레이션에 대해 Gemini-2.5-Flash, Deepseek-V4-Flash 각 50회 시행
- 같은 배분 유형인 100E와 BK21은 대부분의 평가지표에서 유사한 결과 범위를 형성함
- 배분 유형과 규제 유형은 정책 유형에 따라 평가 지표의 **결과 양상에 차이가 존재함**

축	수준	지표	배분 정책		규제 정책	
			100E	BK21	NSA	
Accuracy	미시	Grounding coverage	0.828	0.785	0.730	0.739
	중위	Convergence	0.945	0.939	0.845	0.152
	중위	Value uptake	0.404	0.354	0.350	0.262
	거시	Target error (APE, %)	35.4	37.1	18.1	41.7
	거시	Calibration (50 / 90% interval coverage)	2 / 2	0 / 0	2 / 2	2 / 2
Diversity	거시	Calibration (PIT)	0.470	1.000	0.470	0.650
	미시	Role explained variance (ICC)	0.035	0.028	0.047	0.192
	미시	Semantic dispersion	0.335	0.254	0.185	0.575
	중위	Interaction structure diversity	0.751	0.649	0.587	0.736
	거시	Outcome space width (CV)	0.476	0.329	0.230	0.544

정책 유형별 평가지표 결과 비교



* Deepseek-V4-Flash 기준

Conclusion & Future Work

- 정책 유형별 해석 기준의 차등 적용**: 동일한 평가지표라도 정책 유형에 따라 평가 결과의 방향성이 달라지므로, 정책 시뮬레이션 결과는 단일 기준이 아니라 정책 유형에 따라 해석 기준을 달리 적용해 판단해야 한다.
- 유형론 적용 범위 확장**: 규제 정책의 사례를 보완하고 재분배 정책까지 평가지표 적용 범위를 확장하여, Lowi 정책 유형별 평가 지표 해석 기준의 일반화 가능성을 검증한다.