

검색 로그 분석을 통한 학술 정보 서비스 이용자의 정보 탐색 행태 유형화

지현*, 정다영**, 김재훈**,

한경식† **, 유수현*

*한국과학기술정보연구원 연구지능화센터

**한양대학교 인공지능학과 † 교신저자

e-mail : ji_hyun@kisti.re.kr, dayoungjeong@hanyang.ac.kr,jaehoonkimm@hanyang.ac.kr, kyungsikhan@hanyang.ac.kr, yoosu@kisti.re.kr

Characterizing User Search Behavior in Information Service through Behavioral Log Analysis

Hyun Ji, Dayoung Jeong, Jaehoon Kim, Kyungsik Han, Suhyeon Yoo

1. 서 론

ScienceON은 한국과학기술정보연구원이 운영하는 과학기술서비스로, 국내외 논문과 특허, 국가R&D 보고서, 표·그림, 연구데이터 등 이중 콘텐츠와 연구에 필요한 다양한 인프라를 하나의 창구에서 연계·융합하여 제공한다. 축적된 콘텐츠는 2026년 8월을 기준으로 1억 9천만 건을 넘으며 (192,084,415건), NDSL부터 이어진 폭넓은 이용자층을 기반으로 대표적인 학술 서비스로 자리매김하고 있다.

이에 본 연구에서는 ScienceON를 중심으로 검색 로그를 분석하여 통합 학술 서비스 내의 연구자의 탐색행태를 분석하는 것을 목적으로 하였다. 분석 데이터는 ScienceON의 2026년 3~5월 행동 로그 세션을 대상으로 하였으며, Jansen[1]의 검색 로그 분석 절차에 따라 세션·쿼리·용어의 세 수준에서 이용자 탐색 행태를 분석하고, 군집 분석을 통해 유형별 대표 패턴을 도출하였다.

2. 관련 연구

2.1 검색 로그 분석

Jansen[1]은 검색 로그 분석을 로그 수집·준비·분석의 3단계로 정의하고, 분석 단위를 term, query, session의 세 수준으로 구분하였다. 본 연구는 이 프레임워크를 따르되, 검색 시스템의 성능 평가가 아니라 이용자 행태의 유형화에 초점을 둔다.

2.2 클릭스트림 기반 이용자 유형화

Sadagopan과 Li[3]는 클릭스트림에서 전형적 세션과 비전형적 세션을 통계적으로 구분하였으며, Wang 등[4]은 비지도 학습으로 지배적 행동 패턴을 자동 발견하였다. Marchionini[2]는 정보 탐색을 단순 조회와 탐색적 탐색으로 구분하였다.

3. 연구 방법

3.1 분석 데이터

분석에는 ScienceON의 행동 로그를 활용하였다. 검색 의도가 확인되는 세션만을 대상으로 삼기 위해 검색어가 포함된 세션을 남기고, 콜러 등의 비정상 접근으로 판단되는 세션은 제외하였다. 그 결과 2026년 3~5월 3개월간

2,225,059개 세션을 최종 분석 대상으로 확보하였으며 그 중 3월 행동 로그 583,969건은 별도로 분석하여 전체 분석 결과와의 비교를 위한 지표로 사용하였다.

3.2 세션 유형화

세션은 두 축으로 구분하였다. 첫째, 세션 내 고유 질의 수가 1개인지 2개 이상인지에 따라 single-query (S)와 multi-query (M)로 나누었다. 둘째, 이용자가 특정 자료를 유용하다고 판단했을 가능성을 보여주는 행동, 즉 원문 보기, 인용 정보 확인, 서지 내보내기, 원문 저장, 공유를 정렬 신호(alignment signal)로 정의하고 그 발생 여부에 따라 alignment (A)와 no-alignment (NA)로 구분하였다. 정렬신호를 통해 검색 결과 중 이용자의 정보 자료 도달 여부를 파악하여 이를 세션 유형화에 반영하였다.

3.3 군집 분석

네 유형 각각의 내부 구조를 파악하기 위해 k-means 군집 분석을 수행하였다. 투입 변수는 고유 질의 수, 쿼리 이벤트 수, 조회한 고유 객체 수, 객체 이벤트 수, 세션 체류시간, 그리고 질의 전환의 성격을 나타내는 궤적 유형이다. 변수 간 척도 차이를 보정하기 위해 표준화를 거쳤으며, 세션 체류시간과 이벤트 수에 존재하는 극단값의 영향을 확인하기 위해 원본 데이터, 이상치 포함 데이터, 이상치 제거 데이터의 세 조건으로 각각 군집화를 수행하고 결과의 안정성을 비교하였다. 군집 수는 유형별로 4개로 설정하였다.

4. 분석 결과

4.1 세션 수준

표 1 세션 유형별 규모 및 행태 지표 (n = 2,225,059)

세션 유형	세션 수 (비중)	체류시간	고유 콘텐츠
S + NA	1,634,924 (73.5%)	249.6s	2.01
S + A	371,794 (16.7%)	983.0s	2.97
M + A	159,104 (7.2%)	1,923.7s	6.49
M + NA	59,237 (2.7%)	1,282.8s	11.30

S=single-query, M=multi-query, A=alignment,
NA=no-alignment. 체류시간과 고유 콘텐츠는 평균.

표 1과 같이 single-query 세션이 전체의 90.2%를 차지하였고, 그중 정렬 신호가 없는 S+NA가 73.5%로 가장 큰 비중을 차지하였다. 반면 M+NA는 비중이 2.7%로 가장 작지만 세션당 고유 콘텐츠 수는 11.30개로 네 유형 중 가장 많았다. 정렬 신호에 도달하지 않은 세션이라도 다수의 자료를 넓게 훑는 객체 수준 탐색이 이루어지고 있음을 보여준다.

4.2 쿼리 수준

표 2에서 M+NA의 쿼리 전환 횟수는 4.28회로 M+A의 3.57회보다 오히려 많았다. 이는 질의를 더 많이 바꾸는 것이 정렬 신호 도달을 보장하지 않으며, 반복적 재질의가 성공적 정교화가 아니라 미해결 상태의 지속을 반영할 수 있음을 시사한다. 한편 S+A의 쿼리 이벤트 수가 1.52회로 나타나, 질의를 바꾸지 않은 동일 검색어 맥락 안에서도 정렬이 발생할 수 있음을 확인할 수 있다.

표 2 쿼리 수준 지표 (mean)

세션 유형	쿼리 이벤트	쿼리 전환
S + NA	1.07	0.00
S + A	1.52	0.00
M + A	12.91	3.57
M + NA	10.20	4.28

4.3 용어 수준

용어 수준 분석에서는 연속한 두 질의를 구성하는 용어 집합을 대조하여, 이전 질의에서 그대로 남은 용어(유지), 사라진 용어(제거), 새로 나타난 용어(추가)의 수를 세션 단위로 누적하였다. 세 값의 상대적 크기를 통해 질의 재구성의 성격을 파악하였다. 유지된 용어의 수가 많고 추가 또는 제거된 용어가 적은 경우 검색 범위를 좁히거나 넓히는 부분 수정에 해당하고, 유지된 용어의 수가 작고 추가·제거된 용어가 많은 경우 이전 질의와 겹치는 용어가 거의 없는 주제 전환에 해당한다.

표 3 용어 수준 지표 (mean)

세션 유형	쿼리당 용어	유지	제거	추가
S + NA	1.34	—	—	—
S + A	1.74	—	—	—
M + A	2.32	1.59	6.97	6.99
M + NA	2.17	1.24	6.93	7.03

표 3에서 질의 하나를 구성하는 용어 수는 single-query 유형이 1.34~1.74개, multi-query 유형이 2.17~2.32개로 single-query의 경우가 쿼리를 구성하는 용어의 수가 전반적으로 작았다. 주목할 점은 두 multi-query 유형 모두 유지 용어가 1.2~1.6개에 그친 반면, 제거·추가 용어는 각각 약 7개에 달했다는 것이다. 이용자는 기존 질의의 맥락을 보존하며 범위를 조정하기보다, 겹치는 용어가 거의 없는 새로운 질의로 검색 주제를 크게 바꾸며 이동하고 있음을 의미한다.

이 양상은 정렬 도달 여부와 무관하게 관찰되었다. M+A의 제거·추가 용어 수는 M+NA와 유사하며, 정렬에 이른 세션 역시 점진적 정교화가 아니라 주제 전환을 통해 목표 정보에 도달하고 있음을 확인할 수 있다.

4.4 대표 패턴

군집 분석 결과 각 유형은 소수의 지배적 패턴으로 요약되었다(표 4). S+A에서는 질의 1개로 평균 70초 내에 정렬에

도달하는 “즉시 종결형”이 43.4%, S+NA에서는 19초 내에 이탈하는 “빠른 탐색형”이 53.4%를 차지하였다. M+A와 M+NA에서는 단기 수렴형이 각각 62.1%와 64.5%로 가장 높은 비율을 차지하였으며, 장기 반복탐색형(23.46%)과 집중 재질의형(14.13%)로 각각 그 뒤를 이었다. 3월 사전 분석에서도 S+A의 최대 군집은 43.9%의 즉시 정렬형으로, 비중과 성격이 거의 동일하게 나타났다.

표 4 세션 유형별 최대 군집

세션 유형	최대 군집	비율	특징
S + A	즉시 종결형	43.4%	70초 내 정렬
S + NA	빠른 탐색형	53.4%	19초 내 이탈
M + A	단기 수렴형	62.1%	522초, 반복 질의
M + NA	단기 수렴형	64.5%	196초, 미정렬

4.5 시사점

첫째, 대다수 이용자는 단일 질의로 짧게 탐색하고 종료하므로, 질의 재구성을 전제로 한 검색 지원 기능은 소수 이용자에게만 도달한다. 둘째, 정렬 신호는 질의 전환 횟수보다 체류시간 및 고유 콘텐츠 수와 더 뚜렷하게 연관되어, 이용자 탐색은 질의 수준과 객체 수준이 결합된 다층적 과정으로 이해되어야 한다. 셋째, 노력을 크게 투입하고도 정렬에 도달하지 못한 고노력 미정렬 세션은 단순 이탈이 아니라 미해결 탐색으로, 질의 확장이나 대화형 탐색 지원이 우선 개입해야 할 지점이다.

5. 결론 및 향후 연구 계획

본 연구는 ScienceON 행동 로그 2,225,059개 세션을 질의 재구성 여부와 정렬 신호 발생 여부로 유형화하고, 세션·쿼리·용어의 세 수준에서 각 유형의 특성과 대표 패턴을 제시하였다. 단일 질의로 짧게 종료하는 탐색이 지배적이며, 정렬 여부의 차이는 질의 전환 보다 관련 콘텐츠의 수 혹은 체류시간에서 더 명확하게 나타났다.

본 연구에서 도출한 세션 유형과 대표 패턴은 향후 행동 로그 기반 개인화 서비스 개발의 기반 데이터로 활용할 예정이다. 구체적으로 유형별 탐색 궤적을 학습 데이터로 삼아 세션 진행 중 이용자 유형을 조기에 추정하고, 미해결 탐색으로 판단되는 세션에 질의 확장이나 연관 콘텐츠를 선제적으로 제시하는 방향을 검토하고자 한다.

참 고 문 헌

- [1] B. J. Jansen, “Search log analysis: What it is, what’s been done, how to do it”, Library & Information Science Research, Vol.28, No.3, pp.407-432, 2006.
- [2] G. Marchionini, “Exploratory search: from finding to understanding”, Communications of the ACM, Vol.49, No.4, pp.41-46, 2006.
- [3] N. Sadagopan, J. Li, “Characterizing Typical and Atypical User Sessions in Clickstreams”, Proc. of WWW, pp.885-894, 2008.
- [4] G. Wang, X. Zhang, S. Tang, H. Zheng, B. Y. Zhao, “Unsupervised Clickstream Clustering for User Behavior Analysis”, Proc. of CHI, pp.225-236, 2016.
- [5] 한국과학기술정보연구원, 과학기술 지식인프라 ScienceON, <https://scienceon.kisti.re.kr>, 2026.